



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Uso del algoritmo K-means en la segmentación de
clientes en entornos empresariales.

Use of the K-means algorithm in customer
segmentation in business environments.

Metodología de la Investigación en
Computación

AUTOR:

Katheryn Melissa Contento Maldonado

TUTOR:

Ing. Luis Chamba

Loja, Ecuador

2026

Declaración de Uso de Inteligencia Artificial Generativa

Yo, **Katheryn Melissa Contenido Maldonado**, declaro que en la elaboración del presente trabajo de investigación titulado *Uso del algoritmo K-means en la segmentación de clientes en entornos empresariales*, he hecho uso de herramientas de Inteligencia Artificial Generativa (IAG) de la siguiente manera:

- **Herramienta utilizada:** Modelos de lenguaje a gran escala (LLM) autorizados.
- **Propósito de uso:** Soporte técnico en la estructuración y formateo del código fuente en lenguaje LaTeX, así como en la revisión gramatical y cohesión de estilo académico de los textos.
- **Alcance:** Aplicado en la organización del esqueleto del documento, la corrección ortográfica de las secciones introductorias y la homogeneización visual del código.

Declaro además que el análisis, la interpretación de resultados y las conclusiones son de mi autoría y responsabilidad exclusiva. El uso de IAG no reemplazó el proceso de investigación ni el pensamiento crítico propio.

Autor: Katheryn Melissa Contenido Maldonado

Fecha: Loja, Ecuador, 2026

Índice General

Declaración de Uso de IA Generativa	1
Resumen	3
Abstract	4
1 Introducción	5
2 Planteamiento del Problema	6
2.1 Descripción del Problema	6
2.2 Pregunta de Investigación	6
2.3 Justificación	6
3 Objetivos	8
3.1 Objective General	8
3.2 Objetivos Específicos	8
4 Marco Referencial	9
4.1 Antecedentes	9
4.2 Fundamentos Teóricos	10
4.2.1 Aprendizaje No Supervisado	10
4.2.2 Algoritmo K-means	10
4.2.3 Segmentación de Clientes	11
4.2.4 K-means Aplicado a la Segmentación de Clientes	11
4.3 Marco Conceptual	12
5 Repositorio GitHub	14
Referencias bibliográficas	15

Resumen

El presente trabajo de investigación examina el uso del algoritmo de agrupamiento K-means como una herramienta fundamental para la segmentación de clientes en entornos empresariales contemporáneos. En la actualidad, la masificación de los canales digitales ha generado un volumen sin precedentes de datos transaccionales, lo que imposibilita el uso de métodos analíticos tradicionales. Ante este escenario, surge la pregunta de investigación central: ¿cómo se utiliza el algoritmo K-means en la segmentación de clientes dentro de entornos empresariales para optimizar las estrategias comerciales? Para responder a esta interrogante, se adoptó un enfoque metodológico descriptivo y analítico basado en la revisión sistemática de literatura técnica y casos de estudio aplicados en el comercio electrónico y el sector retail. El proceso metodológico estándar implica la recolección de datos históricos de compra, su transformación mediante el modelo de Recencia, Frecuencia y Valor Monetario (RFM), la estandarización de variables y la aplicación de K-means evaluando el número óptimo de conglomerados a través del método del codo y el coeficiente de silueta. Los principales hallazgos revelan que la integración de K-means permite identificar patrones conductuales complejos, dividiendo de manera eficiente a los consumidores en segmentos estratégicos como clientes de alto valor, compradores leales, clientes en riesgo de abandono y nuevos usuarios transaccionales. Esto facilita a las organizaciones el diseño de campañas de marketing de precisión, la optimización de presupuestos publicitarios y la personalización de servicios. Se concluye que K-means constituye un pilar robusto y de alta escalabilidad computacional en la ciencia de datos comerciales, cuya efectividad óptima depende directamente del preprocesamiento riguroso y la correcta selección de hiperparámetros.

Palabras clave: K-means, segmentación de clientes, aprendizaje no supervisado, agrupamiento, entornos empresariales.

Abstract

The present research work examines the use of the K-means clustering algorithm as a fundamental tool for customer segmentation in contemporary business environments. Currently, the proliferation of digital channels has generated an unprecedented volume of transactional data, making traditional manual analytical methods obsolete. Faced with this scenario, the central research question arises: how is the K-means algorithm used in customer segmentation within business environments to optimize commercial strategies? To address this question, a descriptive and analytical methodological approach was adopted, based on a systematic review of technical literature and applied case studies in e-commerce and the retail sector. The standard methodological workflow involves collecting historical purchase data, transforming it using the Recency, Frequency, and Monetary value (RFM) model, standardizing variables, and executing the K-means algorithm while evaluating the optimal number of clusters via the elbow method and the silhouette score. The main findings reveal that the integration of K-means enables the identification of complex behavioral patterns, efficiently dividing consumers into strategic segments such as high-value customers, loyal buyers, customers at risk of churn, and new transactional users. This allows organizations to design precision marketing campaigns, optimize advertising budgets, and customize services. It is concluded that K-means constitutes a robust and computationally scalable pillar in commercial data science, whose optimal effectiveness depends directly on rigorous preprocessing and the correct selection of hyperparameters.

Keywords: K-means, customer segmentation, unsupervised learning, clustering, business environments.

1. Introducción

En la era digital actual, las empresas interactúan con sus consumidores a través de múltiples canales físicos y digitales, acumulando gigantescos volúmenes de registros diarios. En este panorama, la gestión de las relaciones con el cliente (CRM) y la minería de datos han pasado de ser ventajas competitivas opcionales a convertirse en herramientas críticas de supervivencia empresarial. Dentro de este contexto, el marketing basado en datos surge como una disciplina que busca transformar los datos en bruto en conocimiento accionable, permitiendo a las organizaciones comprender que su base de clientes no es un bloque homogéneo, sino un conjunto diverso con necesidades y patrones de compra heterogéneos.

La segmentación tradicional de clientes solía fundamentarse en variables demográficas estáticas como la edad, el género o la ubicación geográfica. Si bien estos enfoques proporcionaban una estructura básica, resultan insuficientes para predecir las intenciones de compra o la lealtad en mercados altamente dinámicos y competitivos. Es aquí donde el aprendizaje automático (Machine Learning), y específicamente el algoritmo de agrupamiento K-means, ofrece una solución automatizada, ágil y matemáticamente fundamentada. K-means permite agrupar a los clientes en función de su comportamiento transaccional real, revelando estructuras ocultas en los datos sin necesidad de establecer etiquetas previas de clasificación.

Este documento está estructurado de manera lógica para guiar al lector en la comprensión detallada de esta temática. El Capítulo 2 presenta el planteamiento del problema, discutiendo los desafíos comerciales actuales, formulando la pregunta de investigación y su respectiva justificación. El Capítulo 3 detalla los objetivos generales y específicos que guían este estudio. Por último, el Capítulo 4 desarrolla el marco referencial completo, el cual abarca los antecedentes de investigaciones previas, los fundamentos teóricos del aprendizaje no supervisado, el funcionamiento detallado de K-means, los modelos de negocio como RFM y, finalmente, el marco conceptual con definiciones clave.

Este proyecto de investigación aborda la pregunta: *¿Cómo se utiliza K-means en la segmentación de clientes en entornos empresariales?*

2. Planteamiento del Problema

2.1. Descripción del Problema

El principal desafío que enfrentan las empresas modernas es la incapacidad de procesar y comprender eficazmente los masivos conjuntos de datos transaccionales que generan a diario. Cuando una organización carece de mecanismos de segmentación avanzados, se ve obligada a implementar estrategias de marketing y de comunicación comerciales de carácter masivo y genérico. Esta falta de segmentación tiene serias consecuencias financieras y operativas, incluyendo el desperdicio de presupuestos publicitarios en audiencias que no guardan afinidad con los productos ofrecidos, bajas tasas de conversión y un aumento considerable en la tasa de deserción o abandono de clientes (*churn*).

Asimismo, los métodos tradicionales basados en reglas manuales, umbrales fijos o clasificaciones meramente empíricas poseen fuertes limitaciones. Son incapaces de capturar relaciones multidimensionales complejas ni de adaptarse al comportamiento cambiante y dinámico de los usuarios en tiempo real. Al no automatizar el proceso mediante técnicas inteligentes, las corporaciones quedan ciegas ante patrones emergentes, lo que les impide diferenciar de forma objetiva a sus clientes de alto valor de aquellos no rentables, restando competitividad y limitando la personalización de los servicios en un mercado saturado.

2.2. Pregunta de Investigación

La presente investigación se orienta a responder la siguiente pregunta:

¿Cómo se utiliza K-means en la segmentación de clientes en entornos empresariales?

2.3. Justificación

La realización de este estudio posee una profunda relevancia desde tres perspectivas fundamentales: académica, práctica y tecnológica. Desde el punto de vista académico,

la investigación contribuye de manera significativa al cuerpo de conocimientos sobre las aplicaciones del aprendizaje no supervisado y la minería de datos aplicada al comercio, proporcionando un análisis consolidado de cómo los algoritmos matemáticos de particionamiento geométrico se traducen en estrategias de negocio tangibles.

En el ámbito práctico, este trabajo ofrece un beneficio directo a las organizaciones, gerentes y especialistas en marketing, al delinear un flujo de trabajo claro y técnico para subclasificar bases de datos masivas. Esto conduce a una toma de decisiones informada, una mayor fidelización de los usuarios y el diseño de campañas de publicidad de precisión altamente eficientes. Finalmente, en términos tecnológicos, se justifica plenamente por el uso y la validación de herramientas modernas de ciencia de datos, demostrando la viabilidad de implementar soluciones de inteligencia artificial accesibles, reproducibles y escalables en el sector empresarial actual.

3. Objetivos

3.1. Objective General

Analizar el uso del algoritmo K-means en la segmentación de clientes en entornos empresariales, mediante el examen de enfoques metodológicos actuales basados en modelos RFM y la revisión de literatura especializada, para determinar su impacto y efectividad en la optimización de las estrategias de marketing de precisión.

3.2. Objetivos Específicos

1. Describir los fundamentos teóricos del algoritmo K-means y las métricas analíticas empleadas en la literatura científica para determinar el número óptimo de grupos.
2. Identificar los criterios y las variables conductuales del consumidor, tales como las métricas del modelo RFM, que sirven de entrada para el agrupamiento en entornos comerciales digitales.
3. Evaluar casos de estudio documentados sobre la integración de K-means en las estrategias empresariales para determinar sus beneficios y limitaciones en contextos reales de publicidad de precisión.

4. Marco Referencial

4.1. Antecedentes

El estudio de la segmentación de clientes mediante técnicas de agrupamiento automático ha recibido una atención considerable en la literatura científica reciente debido al auge del comercio electrónico. Zhao et al. [1] propusieron una extensión del algoritmo K-means regularizado mediante penalizaciones de tipo *elastic net* para abordar el problema de la segmentación de clientes en entornos omnicanal de alta dimensión con variables correlacionadas, demostrando que supera las limitaciones del K-means estándar al proporcionar menores tasas de error y realizar selección de variables simultáneamente. En el ámbito del marketing digital interactivo, Zhang [2] destaca cómo los algoritmos de Machine Learning mejoran sustancialmente el valor corporativo al refinar la segmentación y la optimización del contenido, sugiriendo que la innovación continua en la personalización es vital para el comercio digital actual.

Por su parte, Vo et al. [3] introdujeron una metodología estructurada que automatiza la selección del parámetro k combinando el modelo RFM y K-means, facilitando una segmentación robusta orientada a estrategias de venta cruzada (*cross-selling*) y venta incremental (*upselling*). Asimismo, Shen [4] demostró la efectividad de aplicar aprendizaje no supervisado (K-means coordinado con PCA y t-SNE) en el comercio electrónico para perfilar consumidores y extraer reglas de asociación potentes a través del algoritmo Apriori, mientras que Wan et al. [5] abordaron la eficiencia computacional proponiendo un modelo RFM rápido que reduce los tiempos de procesamiento en grandes bases de datos.

En entornos corporativos específicos, Zhu [6] formula un modelo de marketing de precisión basado en vectores de características y aprendizaje automático explicable, y Ling et al. [7] presentan un estudio comparativo exhaustivo entre métodos como K-Means++, K-Medoids y predicciones de valor de vida del cliente (CLV), concluyendo que las variantes optimizadas de K-means proveen agrupamientos superiores en términos de cohesión y separación en datos de retail en línea. Finalmente, Cui et al. [8] desarrollaron un algoritmo K-means optimizado por densidad para superar la sensibilidad de los centroides iniciales, logrando una asignación precisa de anuncios en plataformas de comercio electrónico.

4.2. Fundamentos Teóricos

4.2.1. Aprendizaje No Supervisado

El aprendizaje no supervisado representa una rama fundamental del Machine Learning en la cual los modelos analizan conjuntos de datos que no contienen etiquetas previas ni variables objetivo predefinidas. A diferencia del aprendizaje supervisado, donde el algoritmo aprende a predecir un resultado a partir de datos de entrenamiento con respuestas conocidas, el aprendizaje no supervisado opera bajo el principio del autodescubrimiento de estructuras geométricas y patrones ocultos subyacentes. Su propósito principal es identificar similitudes, regularidades o anomalías intrínsecas en los datos. La tarea más común en esta vertiente es el agrupamiento o *clustering*, que busca organizar colecciones de objetos en grupos cuyas características internas sean altamente similares.

4.2.2. Algoritmo K-means

El algoritmo K-means, introducido formalmente por MacQueen y refinado mediante el enfoque de Lloyd, es un método de particionamiento numérico iterativo que divide un conjunto de n observaciones en K clústeres disjuntos. El funcionamiento detallado consta de tres etapas fundamentales ejecutadas cíclicamente:

1. **Inicialización:** Se seleccionan de forma aleatoria o mediante técnicas de densidad (como K-means++) K puntos en el espacio bidimensional o multidimensional de características para actuar como los centroides iniciales $\mu_1, \mu_2, \dots, \mu_K$.
2. **Asignación de puntos:** Cada observación x_i es asignada al clúster cuyo centroide se encuentra a la distancia geométrica más corta, comúnmente evaluada mediante la distancia euclidiana estándar:

$$d(x_i, \mu_j) = \|x_i - \mu_j\| = \sqrt{\sum_{m=1}^d (x_{im} - \mu_{jm})^2} \quad (4.1)$$

3. **Actualización de centroides:** Una vez asignadas todas las observaciones, cada centroide se recalcula como el vector de medias aritméticas de todos los puntos pertenecientes a dicho grupo:

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i \quad (4.2)$$

Este proceso se repite de manera iterativa hasta que los centroides no cambien su posición significativamente o se alcance un criterio de parada. El algoritmo busca

minimizar la función objetivo de la suma de cuadrados internos o inercia (WCSS) expresada en la ecuación 4.3. Para determinar el valor óptimo de K , se recurre a técnicas analíticas como el método del codo (identificando el punto de inflexión de la inercia) y el coeficiente de silueta. En términos de complejidad computacional, el algoritmo es altamente eficiente, con una complejidad temporal expresada como $O(n \cdot k \cdot I \cdot d)$, donde n es el número de muestras, k el número de grupos, I las iteraciones y d las dimensiones.

$$J = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - \mu_j\|^2 \quad (4.3)$$

donde K es el número de clusters, C_j es el j -ésimo cluster, x_i son los puntos de datos asignados a C_j , y μ_j es el centroide del cluster C_j .

4.2.3. Segmentación de Clientes

Desde una perspectiva de negocios, la segmentación de clientes es el proceso estratégico de dividir la base total de consumidores de una empresa en subgrupos homogéneos que comparten características demográficas, psicográficas o conductuales similares. Su utilidad radica en permitir la personalización de las interacciones comerciales, la optimización de los precios y el diseño de ofertas a la medida. Uno de los marcos de modelado conductual más consolidados es el modelo RFM, el cual evalúa el comportamiento basándose en tres métricas cuantitativas clave: Recencia (R), que mide el tiempo transcurrido desde la última transacción del cliente; Frecuencia (F), que contabiliza el número total de transacciones en un periodo dado; y Valor Monetario (M), que representa el gasto total acumulado por el cliente. La segmentación puede clasificarse en demográfica (edad, género), geográfica (país, región), psicográfica (estilo de vida, valores) y conductual (patrones de uso, historial de compras, lealtad), siendo esta última la que mayor beneficio obtiene del análisis avanzado de datos.

4.2.4. K-means Aplicado a la Segmentación de Clientes

La integración de K-means en la segmentación de clientes proporciona un puente matemático entre los datos transaccionales crudos y las decisiones estratégicas de mercadotecnia. K-means es ideal para esta tarea debido a su capacidad para manejar bases de datos comerciales masivas y clasificar de forma objetiva a los usuarios según múltiples dimensiones simultáneamente (como los vectores de características RFM). El flujo metodológico e informático típico en un entorno empresarial sigue los siguientes pasos secuenciales:

1. **Recolección e Ingesta de Datos:** Extracción de registros de ventas y transacciones desde bases de datos relacionales o sistemas ERP/CRM.
2. **Preprocesamiento y Feature Engineering:** Limpieza de datos nulos o anómalos, agregación de transacciones a nivel de cliente para calcular las métricas RFM, y aplicación de técnicas de escalado o normalización (como *StandardScaler*) para evitar que variables con escalas mayores (ej., ingresos monetarios) sesguen las distancias euclidianas.
3. **Ejecución y Ajuste de K-means:** Aplicación iterativa del algoritmo probando múltiples valores de K , y validando los resultados mediante métricas analíticas (Codo y Silueta).
4. **Perfilamiento e Interpretación de Clústeres:** Análisis estadístico de los centroides finales para caracterizar cada segmento en términos de negocio (por ejemplo, un centroide con baja recencia, alta frecuencia y alto valor monetario representa el segmento de "Clientes VIP").
5. **Acción Comercial:** Despliegue de campañas personalizadas, automatización de publicidad de precisión y asignación eficiente de recursos de atención al cliente.

4.3. Marco Conceptual

A continuación se presentan los conceptos clave que fundamentan esta investigación definidos formalmente bajo el estándar de la disciplina:

- **Clustering:** Proceso de agrupar de forma automatizada un conjunto de objetos físicos o abstractos de manera que los objetos del mismo grupo sean más similares entre sí que con los pertenecientes a otros grupos [1].
- **Centroide:** Vector multidimensional que representa la media aritmética o centro geométrico de todas las observaciones asignadas a un clúster determinado dentro del espacio de características [3].
- **Inercia (WCSS):** Métrica que calcula la suma de las distancias al cuadrado de cada punto de datos a su centroide asignado, actuando como la métrica cuantitativa de cohesión intra-clúster [1].
- **Método del codo (*Elbow Method*):** Técnica heurística visual utilizada para determinar el número adecuado de clústeres al graficar la inercia en función de K e identificar el punto de inflexión o quiebre en la curva resultante [3].

- **Coeficiente de silueta (*Silhouette Score*):** Índice analítico que evalúa la calidad del agrupamiento midiendo qué tan cerca está cada punto de los puntos de su propio clúster en comparación con la distancia a los puntos del clúster más cercano [7].
- **Segmentación de clientes:** Estrategia comercial consistente en dividir el mercado o la base de clientes en subgrupos con necesidades, características o comportamientos homogéneos para optimizar la gestión de relaciones y recursos [6].
- **Modelo RFM:** Modelo de análisis de comportamiento del consumidor fundamentado en tres dimensiones cuantitativas clave extraídas del historial transaccional: Recencia, Frecuencia y Valor Monetario [5].
- **Aprendizaje no supervisado:** Categoría del aprendizaje automático orientado al desarrollo de modelos donde la máquina procesa datos de entrada que carecen de etiquetas o respuestas predefinidas, descubriendo estructuras de forma autónoma [2].

5. Repositorio GitHub

[https : //github.com/Kthiu666/Metodologia_Investigacion.git](https://github.com/Kthiu666/Metodologia_Investigacion.git)

Referencias bibliográficas

- [1] H. H. Zhao, X. C. Luo, R. Ma, and X. Lu, “An extended regularized k-means clustering approach for high-dimensional customer segmentation with correlated variables,” *IEEE Access*, vol. 9, pp. 48 405–48 412, 3 2021. [Online]. Available: <https://ieeexplore.ieee.org/document/9381869>
- [2] J. Zhang, “Leveraging machine learning for enhanced online marketing: A comprehensive review of customer segmentation, predictive analytics, and content optimization,” *ACM International Conference Proceeding Series*, pp. 156–159, 12 2024. [Online]. Available: [/doi/pdf/10.1145/3705618.3705644?download=true](https://doi.org/10.1145/3705618.3705644?download=true)
- [3] B. G. Vo, H. D. S. Van, N. D. Van, and H. D. Huynh, “Customer segmentation: Automatic k-optimization and rfm-based k-means clustering,” pp. 173–178, 2 2025. [Online]. Available: [/doi/pdf/10.1145/3731763.3731805?download=true](https://doi.org/10.1145/3731763.3731805?download=true)
- [4] B. Shen, “E-commerce customer segmentation via unsupervised machine learning,” *ACM International Conference Proceeding Series*, vol. PartF168982, 1 2021. [Online]. Available: [/doi/pdf/10.1145/3448734.3450775?download=true](https://doi.org/10.1145/3448734.3450775?download=true)
- [5] S. Wan, J. Chen, Z. Qi, W. Gan, and L. Tang, “Fast rfm model for customer segmentation,” *WWW 2022 - Companion Proceedings of the Web Conference 2022*, pp. 965–972, 8 2022. [Online]. Available: [/doi/pdf/10.1145/3487553.3524707?download=true](https://doi.org/10.1145/3487553.3524707?download=true)
- [6] L. Zhu, “Enterprise customer segmentation and precision marketing model construction based on machine learning,” pp. 996–1001, 10 2025. [Online]. Available: [/doi/pdf/10.1145/3785706.3785861?download=true](https://doi.org/10.1145/3785706.3785861?download=true)
- [7] L. S. Ling and C. T. Weiling, “Enhancing segmentation: A comparative study of clustering methods,” *IEEE Access*, vol. 13, pp. 47 418–47 439, 3 2025. [Online]. Available: <https://ieeexplore.ieee.org/document/10921704>
- [8] Z. Cui, H. Lin, and Q. Zhang, “Precision marketing strategies for e-commerce platforms based on a density-optimized k-means algorithm,” *Proceedings of 2nd International Conference on Machine Intelligence and*

- Digital Applications, MIDA 2025*, pp. 138–145, 7 2025. [Online]. Available: [/doi/pdf/10.1145/3744464.3744486?download=true](https://doi/pdf/10.1145/3744464.3744486?download=true)
- [9] S. Guney, S. Peker, and C. Turhan, “A combined approach for customer profiling in video on demand services using clustering and association rule mining,” *IEEE Access*, vol. 8, pp. 84 326–84 335, 5 2020. [Online]. Available: <https://ieeexplore.ieee.org/document/9085407>
 - [10] R. H. Khan, D. F. Dofadar, M. G. R. Alam, M. Siraj, M. R. Hassan, and M. M. Hassan, “Lrfs: Online shoppers’ behavior-based efficient customer segmentation model,” *IEEE Access*, vol. 12, pp. 96 462–96 480, 6 2024. [Online]. Available: <https://ieeexplore.ieee.org/document/10575928>
 - [11] S. Wu, W. C. Yau, T. S. Ong, and S. C. Chong, “Integrated churn prediction and customer segmentation framework for telco business,” *IEEE Access*, vol. 9, pp. 62 118–62 136, 4 2021. [Online]. Available: <https://ieeexplore.ieee.org/document/9406002>
 - [12] S. Y. Wong, L. Y. Ong, and M. C. Leow, “Aida-based customer segmentation with user journey analysis for wi-fi advertising system,” *IEEE Access*, vol. 12, pp. 111 468–111 480, 7 2024. [Online]. Available: <https://ieeexplore.ieee.org/document/10589400>
 - [13] J. Liao, A. Jantan, Y. Ruan, and C. Zhou, “Multi-behavior rfm model based on improved som neural network algorithm for customer segmentation,” *IEEE Access*, vol. 10, pp. 122 501–122 512, 11 2022. [Online]. Available: <https://ieeexplore.ieee.org/document/9955546>
 - [14] A. S. M. Shaker, M. T. Islam, A. T. Faruq, H. Barua, U. Rozario, M. F. Mridha, and M. J. Hossen, “Tacs-net: Temporal-aware customer segmentation network,” *IEEE Open Journal of the Computer Society*, vol. 6, pp. 1426–1437, 8 2025. [Online]. Available: <https://ieeexplore.ieee.org/document/11134290>
 - [15] Y. Zhang, “Research on customer segmentation using improved k-means algorithm,” *ACM International Conference Proceeding Series*, pp. 98–103, 9 2023. [Online]. Available: [/doi/pdf/10.1145/3660395.3660413?download=true](https://doi/pdf/10.1145/3660395.3660413?download=true)
 - [16] S. Huang, S. Qin, X. Jiang, and Y. Cao, “A travel customer segmentation method based on improved rfm and k-means++,” *ACM International Conference Proceeding Series*, pp. 436–440, 10 2022. [Online]. Available: [/doi/pdf/10.1145/3569966.3570085?download=true](https://doi/pdf/10.1145/3569966.3570085?download=true)

- [17] J. Yuan and R. Wu, “Customer segmentation in highway passenger using clustering analysis,” *Proceedings of 2024 5th International Conference on Big Data Economy and Information Management, BDEIM 2024*, pp. 1146–1151, 5 2025. [Online]. Available: </doi/pdf/10.1145/3724154.3724339?download=true>
- [18] C. Bartels, “Cluster analysis for customer segmentation with open banking data,” *ACM International Conference Proceeding Series*, pp. 87–94, 2 2022. [Online]. Available: </doi/pdf/10.1145/3523181.3523194?download=true>
- [19] P. D. Hung, N. T. T. Lien, and N. D. Ngoc, “Customer segmentation using hierarchical agglomerative clustering,” *ACM International Conference Proceeding Series*, vol. Part F148384, pp. 33–37, 2019. [Online]. Available: </doi/pdf/10.1145/3322645.3322677?download=true>
- [20] Z. Nu and W. Zhou, “Application of machine learning in digital marketing and its optimization modeling in precision advertising delivery——dynamic optimization based on k-means clustering algorithm and q-learning algorithm,” *ACM International Conference Proceeding Series*, pp. 222–226, 12 2024. [Online]. Available: </doi/pdf/10.1145/3705618.3705655?download=true>