

Descripción del Problema Técnico

Nombre: Katheryn Melissa Contento Maldonado

Técnica de IA: K-means

Pregunta de investigación: ¿Cómo se utiliza K-means en la segmentación de clientes en entornos empresariales?

1. Contexto general del problema

En el marco de los Sistemas Inteligentes y la Computación Aplicada, las organizaciones actuales se enfrentan al reto de procesar volúmenes masivos de datos para comprender el comportamiento de sus consumidores[1], [2]. Este desafío es crítico en entornos de alta competitividad y saturación de mercado, como el comercio minorista (Retail), las telecomunicaciones (Telco), el e-commerce y los servicios de Video on Demand (VoD) [3], [4], [5]. En estos sectores, la capacidad de discernir patrones de consumo precisos es fundamental para la toma de decisiones estratégicas y la supervivencia empresarial [1], [2]

.2. Situación actual basada en evidencia

La literatura científica evidencia que el modelo tradicional de segmentación RFM (Recency, Frequency, Monetary) sigue siendo ampliamente utilizado por su simplicidad, pero resulta insuficiente para capturar la naturaleza dinámica y compleja del comportamiento del usuario en línea[3], [5]. Si bien el algoritmo K-means estándar es la técnica más popular para el agrupamiento de clientes debido a su facilidad de implementación, los estudios demuestran que presenta limitaciones técnicas severas [1], [3]. Entre estas destacan su alta sensibilidad a la inicialización aleatoria de centroides, lo que genera resultados inestables, y su pérdida de efectividad cuando se enfrenta a datos de alta dimensionalidad o variables fuertemente correlacionadas [2], [3]

3. Brecha o vacío identificado

A pesar de los avances en técnicas de agrupamiento, persiste una brecha significativa en la capacidad de los modelos convencionales para integrar métricas conductuales más granulares, como la tasa de permanencia (staying rate) o la periodicidad del consumo [1], [5]. Existe, además, una deficiencia en la implementación de marcos analíticos que integren de forma fluida la predicción de abandono (churn) con la segmentación, permitiendo que las empresas no solo sepan quién se va, sino por qué y a qué grupo pertenece[4]. Asimismo, los métodos tradicionales no logran manejar eficientemente la complejidad de los datos multidimensionales sin incurrir en errores de precisión significativos [2]

4. Problema central

El problema radica en la inestabilidad algorítmica y la baja precisión de los métodos de clustering tradicionales al procesar conjuntos de datos empresariales de alta dimensionalidad. Esta limitación técnica impide una identificación exacta y confiable de

perfiles de clientes, lo que genera segmentos borrosos que no reflejan fielmente el valor real o el riesgo de abandono de los usuarios [2], [3], [4]

5. Consecuencias o impacto

Esta situación genera consecuencias financieras directas, como la pérdida de ingresos debido a una alta tasa de churn que no es detectada de manera proactiva[4]. Además, provoca la ineficiencia en el gasto publicitario al saturar a los consumidores con campañas de marketing irrelevantes por falta de personalización [1], [3] . Técnicamente, limita la optimización del Valor de Vida del Cliente (CLV), impidiendo que las empresas asignen sus recursos de retención de manera eficiente hacia los segmentos más rentables [3], [5]

6. Actores involucrados

Los principales actores afectados incluyen a los analistas de marketing y científicos de datos, quienes requieren modelos estables y replicables; los tomadores de decisiones corporativas, cuya planificación estratégica depende de la precisión de los clusters; y las organizaciones de servicios masivos (Telco, Retail, IPTV) que buscan mejorar la lealtad de sus usuarios finales [1], [4]

7. Variables o elementos clave

Las variables técnicas centrales identificadas en las fuentes son:

- Recencia, Frecuencia y Valor Monetario (RFM): Dimensiones base de la transacción [3], [5]
- Longitud (L) y Periodicidad (P): Factores de lealtad temporal y regularidad [1]
- Tasa de Permanencia (Staying Rate - S): Métrica de compromiso digital vinculada a la intención de compra[5]
- Dimensionalidad y Correlación: Atributos del dataset que afectan la convergencia de K-means [2]

8. Delimitación del problema

El presente problema se delimita exclusivamente a la mejora técnica de la segmentación mediante variantes robustas de K-means (como K-Means++, LEN k-means y modelos híbridos con Apriori) aplicadas a datos conductuales en sectores de servicios masivos [1], [2], [4]. No se incluyen en este alcance problemas de infraestructura de servidores o el desarrollo de interfaces gráficas de usuario para el reporte de métricas.

9. Vinculación con la sublínea de investigación

Este problema se enmarca directamente en la sublínea de Inteligencia de Negocios y Minería de Datos, debido a su enfoque en el perfeccionamiento de algoritmos de aprendizaje no supervisado para transformar datos transaccionales brutos en conocimiento estratégico que optimice la relación entre la empresa y el cliente [1], [4], [5].

- [1] S. Guney, S. Peker, y C. Turhan, “A combined approach for customer profiling in video on demand services using clustering and association rule mining”, *IEEE Access*, vol. 8, pp. 84326–84335, may 2020, doi: 10.1109/ACCESS.2020.2992064.
- [2] H. H. Zhao, X. C. Luo, R. Ma, y X. Lu, “An Extended Regularized K-Means Clustering Approach for High-Dimensional Customer Segmentation with Correlated Variables”, *IEEE Access*, vol. 9, pp. 48405–48412, mar. 2021, doi: 10.1109/ACCESS.2021.3067499.
- [3] L. S. Ling y C. T. Weiling, “Enhancing Segmentation: A Comparative Study of Clustering Methods”, *IEEE Access*, vol. 13, pp. 47418–47439, mar. 2025, doi: 10.1109/ACCESS.2025.3550339.
- [4] S. Wu, W. C. Yau, T. S. Ong, y S. C. Chong, “Integrated Churn Prediction and Customer Segmentation Framework for Telco Business”, *IEEE Access*, vol. 9, pp. 62118–62136, abr. 2021, doi: 10.1109/ACCESS.2021.3073776.
- [5] R. Hayat Khan, D. Fabian Dofadar, M. G. R. Alam, M. Siraj, M. Rafiul Hassan, y M. Mehedi Hassan, “LRFS: Online Shoppers’ Behavior-Based Efficient Customer Segmentation Model”, *IEEE Access*, vol. 12, pp. 96462–96480, jun. 2024, doi: 10.1109/ACCESS.2024.3420221.